

基于深度学习的优化器在 CIFAR-10 图像分类任务中的性能对比研究

22.6 班 陈静雯 202200130048

一、研究背景和研究意义

近年来，深度学习技术的快速发展极大地推动了人工智能的进步。在图像识别[1][2]、自然语言处理[3][4]等领域，深度神经网络在多项关键任务中取得了显著成果[5][6]。然而，这些模型性能的提升高度依赖于训练过程的效率与稳定性，如何高效地训练复杂的神经网络模型仍是当前研究中的重要问题。深度学习训练本质上是一个高维非凸优化过程，其复杂性显著高于传统机器学习方法。在这一过程中，优化算法的设计与选择对模型的收敛速度和最终性能具有决定性作用[7]。

优化器在深度学习模型训练中起着核心作用，其主要任务是根据梯度信息确定参数更新的方向和幅度。自早期的随机梯度下降（SGD）方法[8][9]提出以来，优化算法经历了持续的发展与改进。SGD 具有收敛稳定的优点，但其固定学习率策略在复杂损失函数下往往难以取得理想结果。动量法[10]通过引入历史梯度信息缓解了梯度震荡问题，但仍依赖人工调整学习率。自适应优化算法[11]为每个参数动态分配学习率，在一定程度上简化了超参数调节过程。然而，近期研究表明，自适应算法在某些任务中的泛化性能可能不及 SGD，这引发了对不同优化器适用性的进一步讨论。

目前，优化器的选择在很大程度上依赖研究者的经验或既有惯例，缺乏系统的理论指导与实证依据。这种依赖经验的做法可能导致训练效率下降或计算资源浪费，尤其在大规模模型训练中，不合适的优化器选择可能显著增加计算成本。如何在稳定性与收敛速度之间取得平衡，成为深度学习实践中亟需解决的问题。

为系统地研究不同优化算法的性能差异，本文选用 CIFAR-10 数据集作为实验平台。CIFAR-10 是图像分类领域的重要基准数据集[12]，具有规模适中、复杂度适宜等特点，能够在保证实验可重复性的同时，充分反映优化算法的性能差异。包括 VGGNet、ResNet 在内的多种典型网络结构均在该数据集上进行了验证，显示出其在优化算法研究中的代表性。

本文旨在通过系统的对比实验，为深度学习优化器的选择提供实证分析依据。我们在相同实验条件下评估了五种主流优化算法，从收敛速度、最终精度和训练稳定性等方面进行综合比较。研究结果可加深对优化算法特性的理解，并为实际模型训练中的优化策略选择提供参考。随着深度学习模型规模和应用场景的不断扩大，对优化算法进行系统性研究具有重要的理论意义和工程应用价值。本研究通过严谨的对比实验，为优化器选择提供科学的实证依据。我们系统地评估了五种主流优化算法在相同实验设置下的性能表现，从收敛速度、最终精度、训练稳定性等多个维度进行分析。这不仅有助于深化我们对优化算法工作机制的理论理解，更能为实际应用中的算法选择提供实用指导。在深度学习技术日益普及的今天，这样的研究显得尤为必要——它既是对基础理论的深入探索，也是对工程实践的有力支撑。通过揭示不同优化器在标准任务上的真实表现，我们希望为深度学习社区提供有价值的参考，推动人工智能技术向着更高效、更可靠的方向发展。

二、国内外研究现状

优化算法作为深度学习研究的核心组成部分，其发展历程见证了该领域的重要演进。从早期的梯度下降方法到近年来的自适应优化策略，相关研究始终围绕如何实现更高效、更稳定的深度神经网络训练这一核心问题展开。

传统梯度下降算法的研究可追溯至 1951 年 Robbins 和 Monro 提出的随机逼近方法，该方法为随机梯度下降（SGD）奠定了理论基础[14]。早期的总梯度下降方法虽然具备良好的收敛性理论保证，但在大规模数据集上计算代价高昂。SGD 通过在每次迭代中随机采样单个样本计算梯度，显著提高了训练效率，尤其适用于冗余数据集[13]。然而，由于梯度估计的随机性，SGD 的收敛过程常出现震荡，但正是这种随机性使其在某些非凸问题中能够逃离不良局部极小点，表现出优于确定性方法的泛化能力[13]。

1964 年, Polyak 提出的经典动量法[15]通过引入速度项，将历史梯度信息融入当前更新方向，从而平滑了梯度下降轨迹。该方法在深度学习兴起后重新受到重视。Sutskever 等人于 2013 年的研究表明，动量方法不仅能够加快收敛速度，还能一定程度上避免陷入局部最优[16]。随后，Nesterov 在此基础上引入前瞻性梯度估计[17]，进一步提升了参数更新的精度。这类方法的成功表明，利用历史梯度信息能够有效改善优化过程的动态特性。

随着神经网络规模和复杂度的提升，固定学习率策略的局限性日益突出，促使研究者探索自适应学习率算法。2011 年提出的 AdaGrad 算法首次为每个参数分配独立学习率，在稀疏特征场景中表现优异[18]。随后，AdaDelta 和 RMSprop 等对学习率调整机制进行了改进，其中 RMSprop 由 Hinton 在其课程讲义中提出，通过引入梯度平方的指数加权平均，有效缓解了 AdaGrad 学习率持续衰减的问题[19]。这些算法的出现标志着优化方法从统一学习率向参数级自适应更新的转变。

2015 年，Kingma 和 Adam 提出的 Adam 算法[20]是自适应优化算法发展的重要里程碑。Adam 将动量法与自适应学习率思想相结合，通过对梯度一阶与二阶矩的估计实现了动态调整更新幅度，在多数深度学习任务中兼顾了收敛速度与泛化性能。由于其实现简便、适应性强，Adam 迅速成为主流优化器，并被广泛应用于各类深度学习模型训练中。

近年来，优化算法的研究逐渐由结构创新转向对自适应机制、稳定性及泛化能力的精细化理论探索。自 2020 年以来，一系列新研究推动了该领域的持续发展。Liu 等人提出的 RAdam 算法[21]通过引入方差校正项，缓解了训练初期因二阶矩估计偏差导致的学习率不稳定问题，从而在无需额外预热调度的条件下提高了收敛稳定性。Ginsburg 等人提出的 NovoGrad 算法[22]在保持自适应特性的同时，通过分层归一化梯度的方式降低了对大批量训练的依赖，在语音识别与计算机视觉等大规模任务中表现出较好的适用性。

在理论层面，研究者开始更加关注优化算法中的隐式偏差与模型泛化性能之间的关系。Zhang 等人[23]通过理论分析与实证研究指出，在随机梯度呈现重尾分布的场景下，自适应优化方法能够在更新过程中有效控制步长，从而保持训练的稳定性并加快收敛速度。该研究从梯度噪声分布特性的角度，为自适应方法在注意力模型等特定任务上优于 SGD 的现象提供了机制性解释，也进一步揭示了不同优化算法在泛化性能上的差异来源。Zhang 等人的结论在理论上印证并拓展了 Wilson 等人[24]关于自适应优化器泛化局限的早期观察，为理解优化算法的适用边界提供了新的分析视角。

与此同时，融合动量机制与前瞻性梯度估计的新型优化算法不断被提出。Xie 等人提出的 Adan 算法[25]在 Nesterov 动量框架上对梯度更新方式进行了改进，兼顾了动量累积与

自适应调整的优势，在提升收敛稳定性的同时减少了额外计算开销。理论与实验结果表明，Adam 在非凸随机优化问题中具备较优的收敛特性，并在视觉、语言及强化学习等任务上表现出良好的泛化性能。这一发展趋势表明，优化算法的研究正由“自适应学习率”进一步拓展至“自适应更新方向”，体现出优化机制向更高效、更通用范式的演进。

尽管近年来提出了多种优化算法，但系统化的性能评估框架仍较为欠缺。Dogo 等人的研究表明[26]，不同优化器在性能表现上存在明显差异，且其效果受任务类型和数据分布的影响较大。即使在相同的模型结构和超参数设置下，各优化器在收敛速度、精度和稳定性等方面仍存在差异，体现了在超参数鲁棒性和任务迁移性方面的局限。总体来看，现有研究普遍受限于实验设置不统一、评估指标单一等问题，影响了结果的可比性和结论的普适性。因此，建立统一、可复现的跨任务评测框架，并进一步探讨优化算法与损失函数几何特征之间的关系，已成为当前的重要研究方向。

总体而言，优化算法的研究正逐渐由经验探索走向理论系统化，其关注点也从“提出新方法”转向“理解现有机制与构建统一范式”。随着预训练模型的广泛应用和多模态任务复杂度的提升，针对优化过程的可解释性、稳定性及跨任务鲁棒性的研究，正在成为推动深度学习进一步发展的关键方向。

三、研究内容

3.1 研究目标

本研究旨在通过系统化的实验设计，比较分析五种主流优化算法在深度学习图像分类任务中的性能差异。研究重点围绕以下核心问题展开：其一，不同优化器在相同实验环境下的性能表现是否存在显著差异；其二，各优化器在收敛速度、训练稳定性与泛化能力等方面的特征及差异；其三，如何基于实证结果为不同应用场景提供合理的优化器选择依据。

本研究的结论不仅在理论层面有助于加深对优化算法行为机制的理解，也为深度学习模型的实际训练提供了可参考的经验和指导，从而减少因优化器选择不当带来的性能损失与计算资源浪费。

3.2 核心方法

为确保实验结果的科学性与可比性，本研究采用严格的控制变量实验设计。除优化器类型这一自变量外，其余条件（包括模型架构、数据集、超参数配置及训练轮次等）均保持一致，从而尽可能消除外部因素的干扰，使实验结果能客观反映优化器本身的差异。

在评估体系方面，建立了多维度性能评估框架，涵盖准确率、收敛速度、训练稳定性与计算效率四个核心维度。每一维度均设置相应的量化指标，例如最终准确率、达到特定精度所需的训练轮次以及训练过程的性能波动程度等。该评估框架能够较为全面地刻画各优化器的性能特征，避免单一指标评价可能导致的偏差。

此外，本研究引入统计显著性检验方法，对多次实验结果进行方差分析与置信区间计算，以验证性能差异的统计可靠性。通过这一分析过程，确保实验结论具有足够的统计支撑和稳健性，为优化器性能比较提供更加严谨的依据。

3.3 技术路线

本研究的技术路线遵循“统一环境—规范实现—系统分析”的原则，整体过程包括数据

准备、模型构建、优化器实现、训练监测与结果分析五个阶段。

数据层面选用 CIFAR-10 数据集作为基准测试平台。该数据集规模适中、类别平衡，既能保证实验效率，又可反映优化算法在典型视觉任务中的表现差异。

模型构建阶段，采用经典的 VGG11 网络作为实验模型[27]。该网络结构清晰、层次分明，有助于减少模型复杂性对实验结果的干扰。

优化器实现阶段基于 PyTorch 框架完成，确保五种主流优化算法的实现一致、参数设置规范。

训练过程中记录完整的训练动态数据，包括每一轮的损失值、训练准确率与测试准确率等指标，为后续的统计分析提供可靠基础。

最后，结果分析阶段综合运用定量统计与可视化分析方法，从多个角度探讨不同优化器在各性能维度上的差异与特征。

3.4 VGG 模型架构详解

本研究所采用的 VGG11 模型[27]是深度卷积神经网络中的经典代表，其设计思想强调通过小卷积核堆叠实现深层特征提取，体现了“深度优先”的网络结构理念。模型由 8 个卷积层和 3 个全连接层组成。卷积层均采用 3×3 卷积核，并在每层后接 ReLU 激活函数[28]与批量归一化[29]层，以增强非线性表示能力并加快收敛速度。

池化层使用 2×2 最大池化操作，步长为 2，用于逐步降低特征图分辨率并扩大感受野。全连接层部分包含两个 4096 维隐藏层和一个 10 维输出层，对应 CIFAR-10 数据集的 10 个分类类别。

在激活函数方面，采用 ReLU 及其改进形式，以兼顾计算效率与模型表达能力。归一化部分采用批量归一化技术，通过标准化每批样本的特征分布，提升了训练的稳定性与泛化性能。整个网络采用统一的参数初始化策略，确保所有优化器在相同的初始条件下进行训练，为性能比较提供了公平的实验基础。

四、实验设置

4.1 硬件与软件环境

实验在 Google Colab 云计算平台进行，主要计算单元为 NVIDIA Tesla T4 GPU (16GB GDDR6 显存, 2560 个 CUDA 核心)，系统内存 12GB，存储使用临时空间并及时备份关键数据。软件环境基于 Python 3.7+构建，核心框架为 PyTorch 1.12+，配套使用 torchvision 0.13+进行数据处理与模型构建，NumPy 1.21+和 Matplotlib 3.5+用于数值计算与可视化分析。各软件组件版本经过严格验证，确保实验环境稳定且可复现。

4.2 数据集与预处理

实验采用 CIFAR-10 数据集，包含 60,000 张 32×32 彩色图像，均衡分布于 10 个类别，其中 50,000 张用于训练，10,000 张用于测试。训练集数据经过随机裁剪（每边填充 4 像素）、随机水平翻转以及归一化处理，以增强模型平移不变性和数据多样性。测试集仅进行中心裁剪和归一化，以保证评估的一致性。

4.3 模型架构与优化器实现

本实验基于开源代码库 pytorch-cifar10[30] 构建基础训练框架，并在此基础上进行了针对优化器对比的扩展。

基准模型选用 VGG11，包含 8 个卷积层和 3 个全连接层，卷积层使用 3×3 卷积核并配以 ReLU 激活和批量归一化，池化层为 2×2 最大池化，隐藏层维度为 4096，输出层对应 10 个分类。该设计在保证深度的同时有效控制参数规模，便于公平评估不同优化器的性能。

优化器实现包括带动量的 SGD、Adam、AdamW 和 RMSprop，均在 PyTorch 框架下精确复现原论文方法。所有优化器使用统一随机种子初始化，确保实验的可比性和可复现性。

4.4 训练参数与技术路线

训练批量大小为 128，训练轮次 15 个 epoch。学习率根据优化器类型设置：SGD 及动量版本为 0.01，自适应优化器为 0.001，学习率采用余弦退火策略平滑下降。权重衰减系数为 5×10^{-4} ，以控制模型复杂度并抑制过拟合。

实验遵循分阶段技术路线：首先进行数据预处理与模型初始化；随后执行训练，监控损失、训练准确率和测试准确率等关键指标；最后结合定量统计分析与定性可视化方法，对优化器性能在多个维度上进行综合评估。

五、实验结果分析

5.1 准确率与收敛性能

如图 1 测试准确率对比图 1 所示，各优化器在测试集上的准确率表现存在明显差异。Adam 优化器整体表现最佳，最终测试准确率达到 88.80%，其收敛曲线平稳且上升迅速，体现出良好的优化特性。AdamW 紧随其后，准确率为 88.23%，其解耦式权重衰减机制在一定程度上进一步提升了模型的泛化性能。从图 1 可以看出，带动量的 SGD 以 87.57% 的准确率位列第三，虽然收敛速度略慢，但在训练过程中表现出较高的稳定性。图 3 的收敛速度分析结果显示，RMSprop 在本实验条件下表现较弱，仅达到 70.95% 的最终准确率，其收敛过程明显滞后于其他优化器，反映出其在当前任务中的适用性受限。




图 1 测试准确率对比




图 2 最佳测试准确率对比




图 3 收敛速度分析

5.2 训练过程分析

如图 4 所示，各优化器在训练准确率上的演化趋势差异明显。自适应类方法在训练初期便能快速提升准确率，展现出较强的收敛能力，而带动量 SGD 虽上升较为缓慢，但曲线平稳，训练过程波动较小。结合图 4 可以发现，不同优化器在损失下降阶段表现出各自特征：带动量 SGD 下降轨迹平滑，体现出稳定的优化过程；自适应方法下降速度较快，但中后期出现轻微波动；RMSprop 则整体下降迟缓，说明其在当前实验设置下的适应性较弱。




图 4 训练准确率对比




图 5 训练损失对比

5.3 计算效率

从图 6 可以观察到，各优化器在准确率与训练时间之间呈现出不同的平衡特征。Adam 在保持较高准确率的同时，训练时间相对最短，体现出良好的综合效率；带动量 SGD 的训练时间略长，但整体性能仍较为均衡。结合图 7 可以看出，RMSprop 虽然在时间上接近其他方法，但由于准确率明显偏低，整体表现受限。总体来看，自适应优化器在有限计算资源下展现出更优的时间效率与性能权衡。




图 6 效率分析散点图




图 7 训练时间对比

5.4 多维度性能评估

图 8 展示了各优化器在准确率、收敛速度、训练稳定性与计算效率四个维度上的综合表现。整体来看，Adam 与 AdamW 在准确率和收敛速度方面具有明显优势；带动量 SGD 在训练过程的稳定性上表现突出；而在计算效率方面，各方法差异较小，但 Adam 略显优越。综合结果表明，不同优化器在性能维度上各具特点，尚无在所有指标上均表现最优的“通用”方法，实际应用中仍需根据具体任务特征与资源约束进行权衡选择。




图 8 多维度性能分析

5.5 泛化能力

图 9 通过对比训练准确率与测试准确率，揭示了不同优化器的泛化特性。结果表明，带动量 SGD 在泛化能力方面表现最佳，训练与测试准确率的差距最小。Adam 和 AdamW 在训练后期虽出现一定程度的差距扩大，但整体仍处于合理范围之内。值得关注的是，RMSprop 的泛化差距与其他优化器相近，这表明其性能不足主要源于收敛效率较低，而非过拟合问题。




图 9 过拟合分析

5.6 综合性能排名

基于前述多维度分析，图 10 展示了各优化器的综合性能排序。结果表明，Adam 优化器整体表现最优，在兼顾高准确率与训练效率方面具有突出优势；AdamW 位列第二，其改进的权重衰减机制在部分场景中进一步提升了模型表现；带动量 SGD 排名第三，虽在收敛速度上略显缓慢，但以稳定的优化过程和可靠的泛化性能体现出独特价值；RMSprop 相对较弱，但在特定任务和经过充分超参数调整的条件下仍具潜在应用空间。




图 10 性能综合排名

六、结论

本研究基于开源代码库 `pytorch-vgg-cifar10`[30] 构建实验基础框架，通过系统的实验设计和严谨的性能评估，对五种主流深度学习优化器在图像分类任务中的表现进行了全面对比分析。在继承原有 VGG 模型架构和训练流程的基础上，我们扩展了多优化器对比系统、自动化实验流水线和综合评估体系，这些改进使得我们能够在统一的实验环境下获得可靠的对比结果。实验结果表明，不同优化器在准确率、收敛速度、训练稳定性和计算效率等维度展现出显著差异，这些发现为深度学习实践中的算法选择提供了重要的实证依据。

具体来看，Adam 系列优化器在准确率上表现最为突出，其中 Adam 以 88.80% 的测试准确率位列首位，AdamW 紧随其后，准确率为 88.23%。这一结果进一步验证了自适应优化算法在复杂非凸优化问题中的优势，其结合动量和自适应学习率的设计能够有效提升模型性能。带动量的 SGD 尽管最终准确率略低（87.57%），但在训练稳定性方面表现突出，其平滑的收敛轨迹和一致的性能使其在对可靠性要求较高的应用中具有独特价值。相比之下，RMSprop 在本实验设置下表现欠佳，提示在实际应用中应根据任务特性谨慎选择优化算法。

在方法贡献上，本研究构建了一个系统化的优化器评估框架，通过多维度性能指标对优化器进行综合分析，避免了传统单一指标评估可能带来的片面结论。该框架不仅提供了丰富的性能洞察，还为后续研究提供了可扩展的分析工具，同时为深度学习实践者在算法选择上提供了可靠参考，有助于提升模型开发效率。

尽管如此，本研究仍存在一定局限。实验规模相对有限，训练周期较短，可能未充分体现各优化器的长期行为；计算资源限制导致未能对每个优化器进行充分的超参数调优，尤其是表现欠佳的优化器可能在更精细的参数设置下表现更优。此外，本研究仅在单一数据集和模型架构上进行验证，这在一定程度上限制了结论的泛化性。

基于上述发现与局限，未来研究可从以下几个方向展开：首先，将实验扩展至更大规模的数据集和更复杂的模型架构，以检验当前结论在不同任务下的适用性；其次，深入分析优化器的超参数敏感性，建立系统的调参指南；此外，探索优化器组合策略及自适应优化器选择机制也是潜在的研究方向。通过这些工作，有望更加全面地理解优化算法特性，为深度学习实践提供更科学、精准的指导。本研究的价值不仅在于所得的实验结果，更在于建立了一个可扩展的评估范式，为后续研究奠定了基础。

参考文献

- [1] Jia Z, Chen D. Brain tumor identification and classification of MRI images using deep learning techniques[J]. IEEE Access, 2020.
- [2] Rodrigues J N A, Veras R D M S, Neto L S B, et al. Identification of Parkinson's Disease Through Facial Image Classification: A Systematic Review[J]. IEEE Access, 2025.
- [3] AlMeraj Z, Husain F, Arriaga R I. A Cross-Cultural/Lingual Natural Language Processing Analysis of Disability Awareness on Social Media[J]. IEEE Access, 2025.
- [4] Izhar R, Cosh K, Ramingwong L, et al. An Efficient Methodology for the Categorization of Software Requirements Using Natural Language Processing and Similarity Analysis[J]. IEEE Access, 2025.
- [5] Plasek J M, Wyss R D, Weberpals J G, et al. Comparative ranking of marginal confounding impact of natural language processing-derived versus structured features in pharmacoepidemiology[J]. Computers in Biology and Medicine, 2025, 188: 109855.
- [6] Lakyiere A B, Mensah R M O G, Agbenor-Efunam N Y, et al. Trends and advances in image-based mosquito identification and classification using machine learning models: A systematic review[J]. Computers in Biology and Medicine, 2025, 193: 110373.
- [7] Naeem K, Bukhari A, Daud A, et al. Machine learning and deep learning optimization algorithms for unconstrained convex optimization problem[J]. IEEE Access, 2024.
- [8] Liu S, Jiang H, Liu L, et al. Gradient descent using stochastic circuits for efficient training of learning machines[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2018, 37(11): 2530-2541.
- [9] Kuzborskij I, Lampert C. Data-dependent stability of stochastic gradient descent[C]//international conference on machine learning. PMLR, 2018: 2815-2824.
- [10] Yan Y, Yang T, Li Z, et al. A unified analysis of stochastic momentum methods for deep learning[J]. arXiv preprint arXiv:1808.10396, 2018.
- [11] Xu B, Ouyang F, Li Y, et al. An Adaptive Overcurrent Protection Method for Distribution Networks Based on Dynamic Multi-Objective Optimization Algorithm[J]. Algorithms, 2025, 18(8): 472.
- [12] Elgamrani T, Elgaf R, Chtouki Y. Adversarial attack defense techniques: A study of defensive distillation and adversarial re-training on cifar-10 and mnist[C]//2024 International Conference on Computer and Applications (ICCA). IEEE, 2024: 1-4.
- [13] Bottou L. Stochastic gradient learning in neural networks[J]. Proceedings of Neuro-Nimes, 1991, 91(8): 12.
- [14] Robbins, H. and Monro, S. (1951). A stochastic approximation model. Ann. Math. Stat., 22:400 - 407.
- [15] Polyak B T. Some methods of speeding up the convergence of iteration methods[J]. Ussr computational mathematics and mathematical physics, 1964,

4(5): 1-17.

- [16] Sutskever I, Martens J, Dahl G, et al. On the importance of initialization and momentum in deep learning[C]//International conference on machine learning. pmlr, 2013: 1139-1147.
- [17] Nesterov Y. A method for solving the convex programming problem with convergence rate $O(1/k^2)$ [C]//Dokl akad nauk Sssr. 1983, 269: 543.
- [18] Duchi J, Hazan E, Singer Y. Adaptive subgradient methods for online learning and stochastic optimization[J]. Journal of machine learning research, 2011, 12(7).
- [19] Hinton G, Srivastava N, Swersky K. Neural networks for machine learning lecture 6a overview of mini-batch gradient descent[J]. Cited on, 2012, 14(8): 2.
- [20] Kinga D, Adam J B. A method for stochastic optimization[C]//International conference on learning representations (ICLR). 2015, 5(6).
- [21] Liu L, Jiang H, He P, et al. On the variance of the adaptive learning rate and beyond[J]. arXiv preprint arXiv:1908.03265, 2019.
- [22] Ginsburg B, Castonguay P, Hrinchuk O, et al. Stochastic gradient methods with layer-wise adaptive moments for training of deep networks[J]. arXiv preprint arXiv:1905.11286, 2019.
- [23] Zhang J, Karimireddy S P, Veit A, et al. Why are adaptive methods good for attention models?[J]. Advances in Neural Information Processing Systems, 2020, 33: 15383-15393.
- [24] Wilson A C, Roelofs R, Stern M, et al. The marginal value of adaptive gradient methods in machine learning[J]. Advances in neural information processing systems, 2017, 30.
- [25] Xie X, Zhou P, Li H, et al. Adan: Adaptive nesterov momentum algorithm for faster optimizing deep models[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 9508-9520.
- [26] Dogo E M, Afolabi O J, Nwulu N I, et al. A comparative analysis of gradient descent-based optimization algorithms on convolutional neural networks[C]//2018 international conference on computational techniques, electronics and mechanical systems (CTEMS). IEEE, 2018: 92-99.
- [27] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [28] Nair V, Hinton G E. Rectified linear units improve restricted boltzmann machines[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 807-814.
- [29] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
- [30] Chen Y F. pytorch-vgg-cifar10[EB/OL].
<https://github.com/chengyangfu/pytorch-vgg-cifar10>